



UNIVERSITÀ DI PISA

Dipartimento di ingegneria dell'informazione

Master's degree in Artificial Intelligence and data engineering

Smart maintenance for automotive businesses

Corso: Business and Project
Management
Ambito: AI-Driven Business Venture

Autori: [Marco Lari, Tommaso Pellegrini]
Anno accademico: 2025/2026

Gitub Repository: <https://github.com/marcolari06-maker/BPM-project>

Abstract

In this short paper we present how we intend to organize an AI driven startup in the automotive sector, defining the problem we mean to address and the solutions provided. Furthermore we provide a competitor analysis, a business model canvas, a market estimation and a negative backstacking; evaluating the quality of our own project model.

Contents

1	Introduction to the Problem	2
1.1	Triangolazione delle Fonti Informative	3
2	Struttura 1 – Problem/Solution & Product-Market Fit	3
2.1	Definizione del Problema (The Unmet Need)	3
2.2	Soluzione Abilitata dall'Intelligenza Artificiale	3
2.3	Raggiungimento del Product-Market Fit	3
3	Struttura 2 – Analisi della Concorrenza e Posizionamento Strategico	3
3.1	Mappatura dei Concorrenti	3
3.2	Matrice di Valutazione dei Competitor	4
3.3	Strategia di Differenziazione	4
4	Struttura 3 – Business Model Canvas & AI Assets	4
4.1	Componenti del Business Model Canvas (BMC)	4
4.2	Focus sugli Asset AI	4
5	Struttura 4 – Stima del Mercato (TAM, SAM, SOM)	5
5.1	Metodologia di Stima (Top-Down / Bottom-Up)	5
5.2	Dimensionamento Economico	5
6	Struttura 5 – User Personas & Strategia di Validazione	5
6.1	Definizione delle User Personas	5
6.2	Strategia di Validazione sul Mercato	5
7	Struttura 6 – Failure Analysis & Mitigazione del Rischio	6
7.1	Metodologia di Negative Backcasting	6
7.2	Mappatura dei Rischi e Cause di Fallimento	6
7.3	Segnali d'Allarme Precoce (Early Warning Signals) e Mitigazioni	6

1 Introduction to the Problem

The problem addressed in this paper refers to the inefficiencies and consequent high costs of vehicle maintenance in automotive companies, such as transportation, logistic and rental businesses.

Problems

- High maintenance costs
- Downtime and overhead of maintenance work
- Parts reperability issues.

Drivers

- Unexpected failures of critical components (engine, battery pack, transmission). Companies can't predict failures and are forced to wait for them to happen before taking action.
- Unnecessary repairs or replacements to maintain security standard due to lack of predictive maintenance, which leads to periodic schedules or over-maintenance.

Given the above problems and drivers, we aim to provide a solution based on a machine learning model that enables to treat such matters with statistical evidence, such that overhead is reduced due to prediction of failures and costs are reduced with reduction on unnecessary maintenance work. A machine learning approach is suitable for this kind of problem because unlike fixed rules, heuristic or threshold based approaches, it can learn patterns from data to adapt to situations without the need to make rules for every possible scenario. Furthermore it makes the system much more adaptive and scalable, since it can be continuously improved with the collected data, and the data income comes with the normal operation of the vehicles.

This kind of approach is innovative in small automotive companies, since is usually adopted as an internal solution by larger automotive companies, such as OEMs and Tier 1 suppliers. Instead we aim to provide a B2B service that can be adopted by smaller realities, such as logistic companies, rental companies and small fleet owners.

- Small companies don't have the resources to develop such a system internally.
- Previous solutions are heavy on the budget and could be threatening for a upcoming business.

Instead in the proposed solution:

- The system is provided as a service, with a subscription model, such that the company can pay for the service without having to develop it internally.
- The system is designed to be lightweight and easy to integrate with existing systems, such that it can be adopted without major changes to the existing infrastructure.
- Even with the cost of the service the overall cost of maintenance is expected to be lower than the current cost, due to the reduction of downtime and unnecessary maintenance work.

Assumption

The most critical assumption of this project is that companies are willing to share their data, to implement the system. Instead regarding data for training the model, we assume that we can rely on open datasets.

1.1 Triangolazione delle Fonti Informative

Tipologia Fonte	Esempi Utilizzati
Fonti Formali	Brevetti proprietari, normative UE, registri marchi.
Fonti Informali & Open	Datasets pubblici (es. NASA Turbofan, dati diagnostici open), feedback flotte.
Market Intelligence	Report di settore (Gartner, McKinsey Automotive), dati finanziari competitor.

Table 1: Matrice di triangolazione delle fonti per l'analisi evidenziata.

2 Struttura 1 – Problem/Solution & Product-Market Fit

2.1 Definizione del Problema (The Unmet Need)

- **Target del Problema:** Gestori di flotte commerciali, OEM e proprietari individuali di veicoli[cite: 1].
- **Punto Critico (Pain Point):** Guasti imprevisti del motore o del pacco batterie con conseguenti fermi macchina costosi[cite: 1].
- **Limiti delle Soluzioni Attuali:** La manutenzione preventiva a chilometraggio fisso sostituisce componenti ancora funzionanti o interviene troppo tardi su componenti difettosi[cite: 1].

2.2 Soluzione Abilitata dall'Intelligenza Artificiale

- Algoritmi di Machine Learning (Anomaly Detection, Time-Series Forecasting, LSTM/Transformer) per stima della vita utile residua (*Remaining Useful Life - RUL*)[cite: 1].
- Scalabilità del modello tramite Edge-to-Cloud Analytics: elaborazione primaria a bordo veicolo e analisi predittiva complessa in cloud[cite: 1].

2.3 Raggiungimento del Product-Market Fit

- Definizione delle proposizioni di valore differenziate per segmenti B2B (flotte) e B2B2C (OEM/Assicurazioni)[cite: 1].
- Evidenza della convenienza economica: riduzione dei downtime stimata del 30–40% rispetto ai competitor tradizionali[cite: 1].

3 Struttura 2 – Analisi della Concorrenza e Posizionamento Strategico

3.1 Mappatura dei Concorrenti

- **Competitor Diretti:** Startup di AI telematics (es. Stratio, Pitstop)[cite: 1].
- **Incumbent / OEM:** Soluzioni proprietarie dei produttori di veicoli (Bosch Mobility, Continental Diagnostics)[cite: 1].

- **Soluzioni Sostitutive:** Metodi tradizionali di ispezione manuale in officina ed garanzie estese senza diagnostica predittiva[cite: 1].

3.2 Matrice di Valutazione dei Competitor

Competitor	Tipo	Precisione AI	Facilità Integrazione	Conformità Normativa
Competitor A	Startup	Alta	Media	Media
Competitor B	OEM Incumbent	Media	Bassa (Proprietaria)	Alta
Nostra Ven- ture	AI-Driven Venture	Molto Alta	Alta (API Open)	Alta (EU AI Act Compliance)

Table 2: Analisi comparativa del posizionamento competitivo.

3.3 Strategia di Differenziazione

- Vantaggio su modelli proprietari di predizione guasti basati su federated learning[cite: 1].
- Architettura conforme ai requisiti dell'EU AI Act per i sistemi ad alto rischio/automotive[cite: 1].

4 Struttura 3 – Business Model Canvas & AI Assets

4.1 Componenti del Business Model Canvas (BMC)

Customer Segments: Gestori di flotte di veicoli commerciali, Aziende di Noleggio, OEM Automotive[cite: 1].

Value Propositions: Azzeramento dei fermi macchina non pianificati, riduzione del TCO (Total Cost of Ownership), ottimizzazione della pianificazione delle officine[cite: 1].

Channels: Vendita diretta B2B, Integrazione API con gestionali di flotta aziendali, Marketplace automotive[cite: 1].

Revenue Streams: Abbonamento SaaS per veicolo/mese, Modello di rev-share sui risparmi generati dal downtime evitato[cite: 1].

Cost Structure: Costi di infrastruttura cloud/compute, Ricerca e Sviluppo AI, conformità regolatoria e acquisizione dati[cite: 1].

4.2 Focus sugli Asset AI

- **Data Infrastructure:** Pipeline di ingestione dati telemetrici ad altissimo throughput[cite: 1].
- **Model Layer:** Modelli pre-addestrati di pattern-recognition guasti[cite: 1].
- **Compute Infrastructure:** Addestramento distribuito ed edge computing di bordo[cite: 1].

5 Struttura 4 – Stima del Mercato (TAM, SAM, SOM)

5.1 Metodologia di Stima (Top-Down / Bottom-Up)

- **TAM (Total Addressable Market):** Mercato globale della telematica e manutenzione automotive[cite: 1].
- **SAM (Serviceable Addressable Market):** Mercato delle flotte connesse commerciali in Europa/Nord America[cite: 1].
- **SOM (Serviceable Obtainable Market):** Quota di mercato raggiungibile nei primi 3–5 anni di operatività[cite: 1].

5.2 Dimensionamento Economico

Livello di Mercato	Perimetro	Valore Stimato (€)
TAM	Globale Automotive Analytics	€ 45,000,000,000
SAM	Flotte connesse Europa	€ 8,500,000,000
SOM	Flotte commerciali Target (Y1-Y3)	€ 250,000,000

Table 3: Scomposizione e stima quantitativa del mercato target.

6 Struttura 5 – User Personas & Strategia di Validazione

6.1 Definizione delle User Personas

1. Persona 1: Fleet Manager (B2B User)

- *Ruolo:* Responsabile operatività e costi della flotta[cite: 1].
- *Obiettivo:* Massimizzare l'indice di utilizzo dei veicoli ed eliminare i ritardi nelle consegne[cite: 1].
- *Frustrazione:* Costi improvvisi e non preventivati per riparazioni urgenti[cite: 1].

2. Persona 2: Chief Maintenance Officer OEM (B2B Partner)

- *Ruolo:* Gestore garanzie e post-vendita della casa madre[cite: 1].
- *Obiettivo:* Raccogliere dati reali sui guasti per migliorare la progettazione futura[cite: 1].

6.2 Strategia di Validazione sul Mercato

- **Interviste e Survey qualitative:** Validazione delle ipotesi di pain point con 30+ fleet manager[cite: 1].
- **Minimum Viable Product (MVP):** Dashboard di analisi predittiva offline alimentata da log storici di telemetria[cite: 1].
- **Progetti Pilota (Pilot Projects):** PoC (Proof of Concept) di 6 mesi su una flotta pilota di 500 veicoli per misurare l'accuratezza dei preavvisi di guasto[cite: 1].

7 Struttura 6 – Failure Analysis & Mitigazione del Rischio

7.1 Metodologia di Negative Backcasting

Assunzione di partenza: Il progetto è fallito catastroficamente entro 3 anni dal lancio. Si ripercorrono le cause a ritroso[cite: 1].

7.2 Mappatura dei Rischi e Cause di Fallimento

- **Rischio Tecnologico/AI:** High False Positive Rate (troppi allarmi ingiustificati che portano alla perdita di fiducia da parte degli utenti)[cite: 1].
- **Rischio di Mercato:** Bassa adozione da parte dei meccanici od officine per mancanza di competenze digitali[cite: 1].
- **Rischio Regolatorio/Data Governance:** Restrizioni sull'accesso ai dati di bordo del veicolo da parte dei costruttori automobilistici[cite: 1].

7.3 Segnali d'Allarme Precoce (Early Warning Signals) e Mitigazioni

Causa di Fallimento	Early Warning Signal	Azione di Mitigazione
Eccesso di Falsi Allarmi	Churn rate dei clienti pilota > 15%	Fine-tuning dei modelli con metriche di precision-recall conservative[cite: 1].
Ostacoli Regolatori	Difficoltà nell'accesso alle porte OBD	Alleanza strategica con provider di hardware telemetrico aperto[cite: 1].
Mancanza di Interoperabilità	Tempi di integrazione API > 2 mesi	Sviluppo di connettori standardizzati Plug-and-Play per le principali piattaforme[cite: 1].

Table 4: Piano di contingenza basato sull'analisi di Negative Backcasting.

Conclusioni e Prossimi Passi

Questa documentazione costituisce la base metodologica per valutare la fattibilità tecnico-economica della business venture[cite: 1]. La combinazione di rigore ingegneristico nell'ambito AI e approccio di project management garantisce una transizione solida dall'idea alla validazione sul mercato[cite: 1].